

BOOTCAMP EN INTELIGENCIA ARTIFICIAL NIVEL EXPLORADOR

**Informe Técnico
mioplA Visión**

Autores:
Lillency Moreno Garcia
Laura Valentina Balbín Zapata
Andrés Esteban Castrillón Salas

MEDELLÍN
2025



Inteligencia Artificial

miopIA Visión

Historia

Versión	Fecha	Cambiar Descripción



CONTENIDO

	Página
1.1. Entendimiento del Caso	4
1.2. Entendimiento de los Datos	5
1.3. Preparación de los Datos	13
Preprocesamiento y Extracción de Características	14
Creación del Conjunto de Datos	15
Ejemplo de predicción basada en una imagen	15
2. MODELAMIENTO	16
2.1. Justificación de la Técnica	17
1. Robustez ante la Naturaleza de las Variables	17
2. Capacidad para Manejar Relaciones Complejas y No Lineales	18
3. Tolerancia a Datos Ruidosos y Valores Atípicos	18
4. Menor Riesgo de Sobreajuste (Overfitting)	18
5. Importancia de las Características	19
6. Rendimiento y Escalabilidad	19
2.2. Consideraciones al Aplicar	20
2.3. Parametrización de RandomForest Classifier	22
3. EVALUACIÓN E IMPLEMENTACIÓN	28
3.1. Evaluación	29
1. Robustez ante la Heterogeneidad de los Datos Visuales	29
2. Detección de Patrones Intrincados para Diagnósticos Diferenciales	30
3. Fiabilidad ante la Variabilidad de las Imágenes Clínicas	30
4. Capacidad de Generalización y Mitigación del Sobreajuste	30
5. Fundamentación en la Importancia de las Características	31
3.2. Implementación	31
3.3. Plataforma y Herramientas	32
3. CONCLUSIONES	35
Conclusiones del Caso de Aplicación Seleccionado	35
Conclusiones de la Técnica Seleccionada (Random Forest)	35
Conclusiones del Método Seleccionado (Sistema de Predicción Basado en Características Visuales)	36
Consideraciones Personales (Implícitas en el Proyecto)	37



CASO DE APLICACIÓN

1.1. Entendimiento del Caso

El proyecto estará enmarcado en *Ciencia, tecnología e innovación para la transformación social*. La **salud visual** es un pilar fundamental para la calidad de vida y el desarrollo individual y colectivo. Sin embargo, el acceso a diagnósticos tempranos y precisos de afecciones oculares sigue siendo un desafío significativo en muchas comunidades. En este contexto, la **ciencia, la tecnología y la innovación** se erigen como herramientas poderosas para generar una **transformación social profunda**, democratizando el acceso a soluciones de salud visual.

Nuestro proyecto se inscribe en esta visión, buscando revolucionar la forma en que se identifican y gestionan las **condiciones visuales** más comunes. A través de la aplicación de **tecnologías avanzadas**, como la inteligencia artificial y el procesamiento de imágenes, hemos desarrollado un sistema capaz de **predecir** de manera eficaz y temprana entre las siguientes categorías: **visión normal, estrabismo, cataratas, conjuntivitis, ojos secos o la necesidad de una consulta especializada**.

Esta capacidad predictiva no solo optimiza los tiempos de diagnóstico, sino que también permite una **intervención más oportuna**, previniendo el avance de enfermedades y mejorando los pronósticos para los pacientes. Imaginemos el impacto social: desde la detección temprana de estrabismo en niños, que puede evitar problemas de desarrollo visual a largo plazo, hasta la identificación de cataratas en adultos mayores, facilitando el acceso a tratamientos que restauran su independencia.

La implementación de esta tecnología representa un paso gigante hacia la **equidad en salud**. Al ofrecer una herramienta accesible y precisa, reducimos las barreras geográficas y económicas que a menudo impiden a las personas buscar atención oftalmológica. Esto se traduce en comunidades más saludables, productivas y con una mejor calidad de vida.

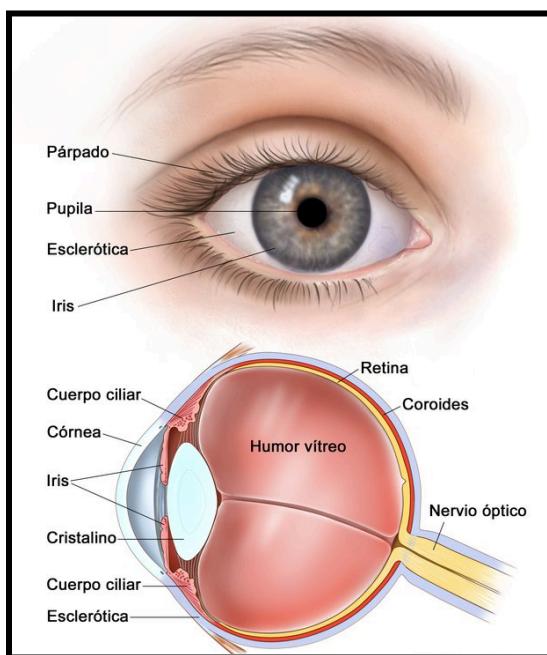
En definitiva, este proyecto no es solo un avance tecnológico; es una declaración de nuestro compromiso con la **transformación social** a través de la innovación. Estamos construyendo un futuro donde la buena visión sea un derecho al alcance



de todos, empoderando a las personas y construyendo comunidades más fuertes y resilientes.

1.2. Entendimiento de los Datos

Este proyecto se basa en un conjunto de datos estructurado para predecir diversas condiciones visuales: visión normal, estrabismo, cataratas, conjuntivitis, ojos secos o la necesidad de una consulta especializada. La precisión de nuestras predicciones radica en la cuidadosa cuantificación y análisis de siete variables clave, cada una de las cuales proporciona información crucial sobre el estado ocular del paciente. A continuación, se detalla la interpretación de cada variable:



Alineación ocular: Esta variable, de escala ordinal, evalúa la posición de los ojos. Es fundamental para identificar el estrabismo, una condición donde los ojos no se alinean correctamente.

- **0: Ortotropia (Alineación normal):** Indica que ambos ojos están perfectamente alineados y enfocados en el mismo punto.



- **1: Micro-estrabismo / Desviación muy leve:** Una desviación apenas perceptible o intermitente, que podría requerir una observación más detallada para su confirmación.
- **2: Desviación moderada:** La desalineación es claramente visible a simple vista, pero no extrema.
- **3: Desviación severa:** Una desviación muy notoria y constante de uno o ambos ojos, indicando un estrabismo pronunciado.



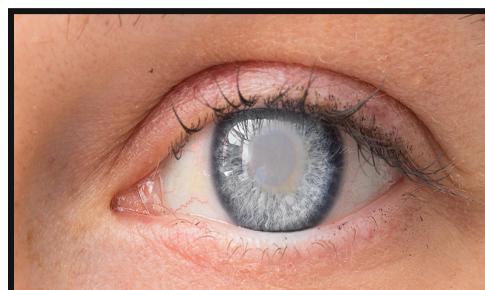
Enrojecimiento de la conjuntiva: Utilizando una escala ordinal (0-4), esta variable mide el grado de enrojecimiento de la conjuntiva, la membrana que recubre la parte blanca del ojo y el interior de los párpados. Es un indicador clave de inflamación, común en condiciones como la conjuntivitis y los ojos secos.

- **0: Ausente / Ninguno:** La conjuntiva está completamente blanca, sin vasos sanguíneos prominentes.
- **1: Muy leve:** Vasos sanguíneos apenas visibles o muy finos, con un enrojecimiento mínimo.
- **2: Leve:** Vasos sanguíneos más visibles, con un enrojecimiento sutil pero no generalizado.
- **3: Moderado:** Vasos sanguíneos bien definidos y numerosos, con un enrojecimiento difuso en el ojo.
- **4: Severo:** Enrojecimiento muy intenso y difuso, con vasos sanguíneos muy dilatados y congestionados, indicando una inflamación significativa.



Claridad/Opacidad de la córnea: Esta variable ordinal (0-4) evalúa la transparencia de la córnea, la capa frontal transparente del ojo. Las opacidades pueden ser un signo de diversas afecciones, incluyendo infecciones o lesiones.

- **0: Transparente:** La córnea está completamente clara, sin ninguna opacidad o irregularidad visible.
- **1: Muy leve opacidad/irregularidad:** Apenas perceptible, requiere observación detallada para su detección.
- **2: Leve opacidad/irregularidad:** Claramente visible pero no interfiere significativamente con la visibilidad del iris o la pupila.
- **3: Moderada opacidad/irregularidad:** Interfiere parcialmente con la visibilidad de las estructuras internas del ojo.
- **4: Severa opacidad/irregularidad:** La córnea está muy nublada o con gran distorsión, comprometiendo o anulando la visibilidad de las estructuras internas.





Claridad/Opacidad de la pupila y el cristalino: También una escala ordinal (0-4), inspirada en el sistema LOCS III, esta variable se enfoca en la transparencia del cristalino (lente del ojo) y la apariencia de la pupila. Es crucial para la detección de cataratas.

- **0: Claro:** La pupila es negra y el cristalino es transparente, sin opacidades visibles.
- **1: Muy leve opacidad:** Opacidad incipiente, apenas visible, que no afecta significativamente la visibilidad del reflejo rojo pupilar.
- **2: Leve opacidad:** Opacidad claramente visible, pero no densa, que puede afectar el reflejo rojo.
- **3: Moderada opacidad:** Opacidad densa que cubre una parte significativa de la pupila, afectando claramente la visibilidad.
- **4: Severa opacidad:** Opacidad muy densa, a menudo blanquecina, que cubre la mayor parte o la totalidad de la pupila, bloqueando completamente la visibilidad.

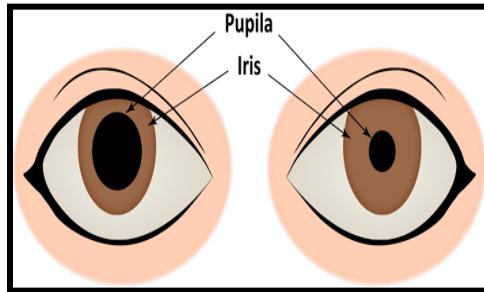


Tamaño y Simetría de la pupila: Esta variable se centra en la simetría pupilar, con una escala binaria. La asimetría (anisocoria) puede indicar diversas condiciones neurológicas u oculares.

- **0: Simétricas:** Ambas pupilas tienen un tamaño y forma iguales o casi iguales.



- **1: Asimétricas:** Las pupilas tienen tamaños diferentes (anisocoria) o formas irregulares.



6. Presencia de Secreciones o Descargas: Una variable ordinal (0-3) que cuantifica la cantidad de secreción ocular, un síntoma común en la conjuntivitis y, en menor medida, en ojos secos severos.

- **0: Ausente:** No hay secreciones visibles.
- **1: Leve:** Pequeña cantidad de secreción, como un ligero lagrimeo o mucosidad en los cantos del ojo.
- **2: Moderado:** Cantidad visible de secreción, que puede estar esparcida por el borde del párpado o en las pestañas.
- **3: Abundante/Severo:** Gran cantidad de secreción, cubriendo parte de las pestañas o el ojo, a menudo con costras, indicando una infección o inflamación significativa.





7. Apariencia de los Párpados: Esta variable ordinal (0-3) evalúa signos de inflamación, edema o anomalías en la piel de los párpados, relevantes para condiciones como la conjuntivitis y los ojos secos.

- **0: Normal:** Párpados de apariencia regular, sin hinchazón, enrojecimiento o descamación.
- **1: Leve:** Mínima hinchazón o enrojecimiento apenas perceptible.
- **2: Moderado:** Hinchazón o enrojecimiento evidente, puede haber descamación o signos de irritación.
- **3: Severo:** Hinchazón prominente, enrojecimiento intenso, posiblemente con lesiones cutáneas o signos de infección evidente.



La combinación y el análisis de estas siete variables nos permiten construir un modelo robusto para la predicción de condiciones visuales, facilitando diagnósticos tempranos y precisos para una mejor salud ocular. A continuación, se detalla la interpretación de cada condición visual a predecir:

Estrabismo Una imagen que muestra un ojo con una desviación muy notoria y constante (Alineación Ocular: 3), mientras que el resto de las variables (Enrojecimiento de la Conjuntiva, Claridad/Opacidad de la Córnea, Claridad/Opacidad de la Pupila y el Cristalino, Tamaño y Simetría de la Pupila, Presencia de Secreciones o Descargas, Apariencia de los Párpados) se mantienen en un estado normal (0).



Conjuntivitis Una imagen que ilustra un ojo con enrojecimiento muy intenso y difuso de la conjuntiva (Enrojecimiento de la Conjuntiva: 4), una gran cantidad de secreción con costras (Presencia de Secreciones o Descargas: 3), y párpados hinchados y muy rojos (Apariencia de los Párpados: 3). Las demás variables (Alineación Ocular, Claridad/Opacidad de la Córnea, Claridad/Opacidad de la Pupila y el Cristalino, Tamaño y Simetría de la Pupila) permanecen en estado normal (0).



Cataratas Una imagen que representa un ojo con una opacidad muy densa y blanquecina que cubre la mayor parte o la totalidad de la pupila, bloqueando la visibilidad (Claridad/Opacidad de la Pupila y el Cristalino: 4). Las otras variables (Alineación Ocular, Enrojecimiento de la Conjuntiva, Claridad/Opacidad de la Córnea, Tamaño y Simetría de la Pupila, Presencia de Secreciones o Descargas, Apariencia de los Párpados) se muestran en estado normal (0).



Ojos Secos: Una imagen de un ojo con enrojecimiento difuso y vasos sanguíneos numerosos y bien definidos en la conjuntiva (Enrojecimiento de la Conjuntiva: 3). Se observa una cantidad visible de secreción esparcida por el borde del párpado (Presencia de Secreciones o Descargas: 2), y los párpados muestran hinchazón y enrojecimiento evidente (Apariencia de los Párpados: 2). Las variables restantes (Alineación Ocular, Claridad/Opacidad de la Córnea, Claridad/Opacidad de la Pupila y el Cristalino, Tamaño y Simetría de la Pupila) están en estado normal (0).



Visión Normal Una imagen de un ojo completamente sano, donde todas las variables se encuentran en su estado normal (0): alineación ocular, conjuntiva blanca sin vasos prominentes, córnea transparente, pupila negra y cristalino transparente, pupilas simétricas, ausencia de secreciones y párpados de apariencia regular.



1.3. Preparación de los Datos

Para que nuestro proyecto de predicción de condiciones visuales tenga éxito, la calidad y el procesamiento de las imágenes son tan cruciales como los algoritmos de inteligencia artificial que las analizan. La preparación de estas imágenes implica un proceso meticoloso para asegurar que los datos visuales sean consistentes, informativos y estén listos para ser interpretados por el modelo predictivo.

Nuestro conjunto de datos de imágenes para este proyecto fue extraído de **Kaggle** (<https://www.kaggle.com/datasets>), una plataforma líder para la ciencia de datos. De esta fuente, hemos recopilado un total de **1722 imágenes**, distribuidas de la siguiente manera para cada condición visual:

- **Estrabismo:** 400 imágenes
- **Cataratas:** 410 imágenes
- **Conjuntivitis:** 407 imágenes
- **Ojos Secos:** 105 imágenes
- **Visión Normal:** 400 imágenes

El objetivo principal de la preparación es extraer de cada imagen los **valores numéricos de las siete variables clave** que has definido. Esto transformará la información visual en datos estructurados que el modelo puede "entender" y usar para hacer sus predicciones (visión normal, estrabismo, cataratas, conjuntivitis, ojos secos o consulta especializada).



Preprocesamiento y Extracción de Características

Una vez adquiridas, las imágenes pasan por un proceso de preprocesamiento y extracción de características, automatizado mediante técnicas de visión por computador:

1. **Normalización de Color y Contraste:** Se ajustan los colores y el contraste para compensar pequeñas variaciones de iluminación que no pudieron evitarse en la captura. Esto asegura que, por ejemplo, el **Enrojecimiento de la Conjuntiva** se evalúe de manera consistente en diferentes imágenes.
2. **Segmentación y Análisis por Variable:**
 - **Alineación ocular:** Se analizan las posiciones relativas de los ojos. Algoritmos pueden detectar el centro de las pupilas y la posición de los reflejos de luz (reflejo de Hirschberg) para cuantificar la desviación angular y asignarle un valor de 0 a 3. Si un solo ojo es visible, se infiere la alineación basándose en la posición del centro de la pupila.
 - **Enrojecimiento de la conjuntiva:** Se segmenta la conjuntiva y se analizan sus píxeles. Se pueden usar algoritmos para medir la intensidad del color rojo y la densidad de los vasos sanguíneos, asignando un valor de 0 a 4 según la escala de Efron/CCLRU.
 - **Claridad/Opacidad de la córnea:** Se enfoca en el área de la córnea. Se analiza la uniformidad y transparencia de los píxeles, detectando cualquier nebulosidad o irregularidad para asignar un valor de 0 a 4.
 - **Claridad/Opacidad de la pupila y el cristalino:** El área de la pupila se examina para detectar opacidades. Un ojo sano mostrará una pupila uniformemente negra. La presencia y densidad de cualquier área blanquecina o nublada dentro o detrás de la pupila se cuantifica de 0 a 4, imitando una versión simplificada de la escala LOCS III.



- **Tamaño y simetría de la pupila:** Se detecta el contorno de ambas pupilas. Se calcula su diámetro y se compara para determinar si hay asimetría (anisocoria), asignando un 0 (simétricas) o un 1 (asimétricas).
- **Presencia de secreciones o descargas:** Se analizan los bordes de los párpados y la superficie ocular en busca de cualquier acumulación de líquido, mucosidad o costras, cuantificando su presencia y volumen de 0 a 3.
- **Apariencia de los párpados:** Se examina la piel y el volumen de los párpados para detectar signos de hinchazón, enrojecimiento, descamación o lesiones, asignando un valor de 0 a 3.

Creación del Conjunto de Datos

Cada imagen, una vez analizada, se transforma en un **vector de características**, es decir, una fila de datos con los 7 valores numéricos correspondientes a las variables. Esta fila de datos se empareja con la **etiqueta de diagnóstico** (visión normal, estrabismo, etc.) que ha sido confirmada por un especialista. Este conjunto de pares (vector de características, etiqueta de diagnóstico) es lo que entrena al modelo de inteligencia artificial para aprender patrones y hacer predicciones.

Ejemplo de predicción basada en una imagen

Imagina que capturamos la imagen de un ojo y nuestro sistema de procesamiento de imágenes extrae las siguientes características:

- **Alineación Ocular:** 0 (Ortotropia)
- **Enrojecimiento de la Conjuntiva:** 3 (Moderado - vasos bien definidos y numerosos, enrojecimiento difuso)
- **Claridad/Opacidad de la Córnea:** 0 (Transparente)



- **Claridad/Opacidad de la Pupila y el Cristalino:** 0 (Claro)
- **Tamaño y Simetría de la Pupila:** 0 (Simétricas)
- **Presencia de Secreciones o Descargas:** 2 (Moderado - cantidad visible de secreción)
- **Apariencia de los Párpados:** 2 (Moderado - hinchazón o enrojecimiento evidente)

Con estos valores, el modelo, entrenado previamente con miles de imágenes, identificaría un patrón claro de **conjuntivitis**. Los altos niveles de enrojecimiento de la conjuntiva, la presencia de secreciones y la inflamación de los párpados, combinados con la normalidad de otras variables como la córnea o el cristalino, apuntan de manera concluyente a esta condición.

Este proceso de transformar una imagen compleja en un conjunto de datos estructurado y significativo es el corazón de nuestro proyecto, permitiéndonos aplicar el poder de la inteligencia artificial para mejorar la salud visual de las personas.



2. MODELAMIENTO

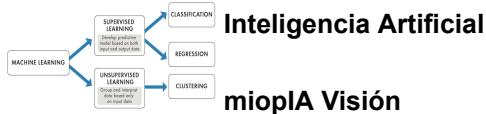
2.1. Justificación de la Técnica

Para un proyecto que busca predecir condiciones visuales como estrabismo, cataratas, conjuntivitis, ojos secos o visión normal, basándose en siete variables clave extraídas de 1722 imágenes, la elección del método de clasificación es fundamental. En este contexto, el **algoritmo de clasificación Random Forest** se presenta como una opción robusta y altamente justificada, ofreciendo ventajas significativas sobre otros enfoques.

Random Forest es un método de **aprendizaje de conjunto** que opera construyendo múltiples árboles de decisión durante el entrenamiento y produciendo la clase que es la moda de las clases (clasificación) o la predicción media (regresión) de los árboles individuales. Su idoneidad para nuestro proyecto se basa en las siguientes razones:

1. Robustez ante la Naturaleza de las Variables

Nuestras siete variables (Alineación Ocular, Enrojecimiento de la Conjuntiva, Claridad/Opacidad de la Córnea, Claridad/Opacidad de la Pupila y el Cristalino, Tamaño y Simetría de la Pupila, Presencia de Secreciones o Descargas y Apariencia de los Párpados) son predominantemente de **escala ordinal**. Los árboles de decisión, y por ende Random Forest, manejan naturalmente este tipo de datos sin necesidad de una codificación compleja, a diferencia de otros modelos que requieren transformaciones extensas. Esta característica simplifica el preprocessamiento y reduce la posibilidad de introducir errores.



2. Capacidad para Manejar Relaciones Complejas y No Lineales

Las condiciones visuales a menudo no se manifiestan de manera lineal. Por ejemplo, una combinación de enrojecimiento moderado y una pequeña cantidad de secreción podría indicar ojos secos, mientras que un enrojecimiento severo con abundante secreción podría ser conjuntivitis. Random Forest, al construir múltiples árboles de decisión que exploran diferentes subconjuntos de datos y características, es intrínsecamente capaz de **capturar estas interacciones complejas y relaciones no lineales** entre las variables, lo que se traduce en una mayor precisión predictiva.

3. Tolerancia a Datos Ruidosos y Valores Atípicos

En el procesamiento de imágenes médicas, especialmente si las imágenes provienen de diversas fuentes o calidades, es posible encontrar **datos ruidosos o valores atípicos** en la cuantificación de las variables. Random Forest es conocido por su **robustez y resistencia a estos ruidos**. Al promediar las predicciones de muchos árboles, el impacto de un único árbol influenciado por datos anómalos se minimiza, lo que conduce a un modelo más estable y confiable.

4. Menor Riesgo de Sobreajuste (Overfitting)

Un desafío común en el aprendizaje automático es el **sobreajuste**, donde el modelo aprende demasiado bien los datos de entrenamiento y falla al generalizar a nuevos datos. Aunque los árboles de decisión individuales pueden ser propensos al sobreajuste, Random Forest lo mitiga eficazmente. La construcción de múltiples árboles con **muestreo de datos (bagging)** y la **selección aleatoria de características** para cada división de árbol aseguran una diversidad entre los árboles, reduciendo significativamente la varianza y el riesgo de sobreajuste. Esto es crucial para un dataset de 1722 imágenes, donde queremos que el modelo sea efectivo en el diagnóstico de nuevas imágenes no vistas durante el entrenamiento.



5. Importancia de las Características

Random Forest proporciona una métrica de **importancia de las características**. Esto nos permite identificar cuáles de nuestras siete variables son las más influyentes en la predicción de cada condición visual. Por ejemplo, podríamos descubrir que la "Claridad/Opacidad de la Pupila y el Cristalino" es la variable más crítica para detectar cataratas, mientras que el "Enrojecimiento de la Conjuntiva" es clave para la conjuntivitis. Esta capacidad de **interpretabilidad** es invaluable para comprender mejor la contribución de cada factor al diagnóstico y para futuras optimizaciones del modelo o del proceso de recolección de datos.

6. Rendimiento y Escalabilidad

A pesar de su complejidad interna, Random Forest es un algoritmo computacionalmente eficiente y puede **escalar bien** con conjuntos de datos de tamaño moderado como el nuestro (1722 imágenes). Su capacidad de procesamiento en paralelo (debido a la independencia de la construcción de cada árbol) lo hace atractivo para entornos con recursos computacionales limitados.

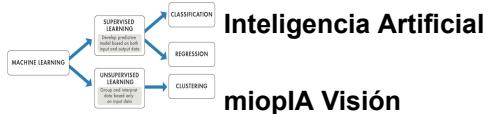
En conclusión, la aplicación de **Random Forest** no solo es una elección pragmática dada la naturaleza de nuestras variables y el tamaño del dataset, sino que también ofrece un marco predictivo potente, interpretable y resistente. Su capacidad para manejar la complejidad de los datos oculares y su probada eficacia en tareas de clasificación lo convierten en el método idóneo para lograr predicciones precisas y contribuir a la transformación social a través de la salud visual.



2.2. Consideraciones al Aplicar

El clasificador se basa en la extracción de características visuales de las imágenes de ojos para predecir un problema visual. Las consideraciones clave para aplicar este método fueron:

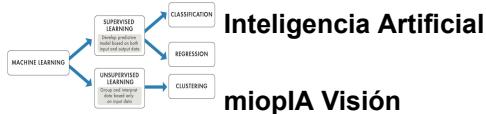
- 1. Naturaleza del problema:** La tarea es clasificar imágenes en diferentes categorías de problemas visuales (o visión normal). Esto sugiere un problema de clasificación supervisada, donde se dispone de un conjunto de datos de entrenamiento con imágenes etiquetadas.
- 2. Datos de entrada (Imágenes):** La entrada son imágenes. Los modelos de clasificación basados en aprendizaje automático a menudo requieren características numéricas como entrada, no directamente las imágenes en su formato raw de píxeles.
- 3. Complejidad de las características visuales:** Identificar problemas visuales como estrabismo, conjuntivitis o cataratas implica reconocer patrones y características específicas en las imágenes (alineación, enrojecimiento, opacidad, etc.). Extraer estas características de manera programática requiere técnicas de procesamiento de imágenes.
- 4. Disponibilidad de datos de entrenamiento:** Se asume la disponibilidad de un conjunto de imágenes de entrenamiento con etiquetas predefinidas para cada problema visual. Sin estos datos etiquetados, sería difícil entrenar un modelo supervisado.
- 5. Elección del clasificador:** Se seleccionó un RandomForestClassifier. Las consideraciones para esta elección (aunque no se detallan explícitamente en el código como el por qué se eligió este específico) podrían incluir:
 - a. Buen rendimiento en tareas de clasificación:** Random Forest son conocidos por su robustez y buen rendimiento en una variedad de problemas de clasificación.



- b. Manejo de características de diferente naturaleza:** Aunque las características extraídas son todas numéricas, su origen (alineación, color, textura, etc.) es diverso.
- c. Menos sensible al sobreajuste** que otros modelos como árboles de decisión individuales.
- d. Relativa facilidad de implementación y comprensión.**

6. Extracción de Características (`_extract_features_from_image`): Esta es la parte central que define cómo se representa una imagen para el clasificador. Las consideraciones aquí fueron:

- a. Identificación de indicadores clave:** Se definieron 7 características basadas en indicadores visuales comunes de problemas oculares.
- b. Uso de librerías de procesamiento de imágenes:** Se utilizó cv2 (OpenCV) para realizar operaciones básicas de procesamiento de imágenes como leer imágenes, convertir espacios de color (gris, HSV), detección de bordes (Canny) y detección de círculos (HoughCircles).
- c. Simplificación/Heurísticas:** Es importante notar que muchas de las características (Alineación, Enrojecimiento, Claridad Córnea, Claridad Pupila/Cristalino, Secreciones, Apariencia Párpados) se implementaron de forma simplificada y heurística para la demostración. En una aplicación real, la extracción de estas características sería mucho más sofisticada y requeriría algoritmos de visión por computadora más avanzados (detección de objetos, segmentación, análisis de texturas detallado, etc.).
- d. Escalado de características:** Aunque no se realiza explícitamente un escalado de características como normalización o estandarización (común antes de entrenar algunos modelos), las puntuaciones de las características se escalan a rangos pequeños (0-4, 0-3, 0/1).



Inteligencia Artificial

miopia Visión

e. Reglas de anulación/sugerencia: Se incluyeron reglas basadas en umbrales simples sobre las características extraídas (por ejemplo, si el enrojecimiento es alto, clasificar como conjuntivitis). Esta es una consideración práctica para incorporar conocimiento del dominio, aunque en un sistema puramente basado en ML, estas reglas podrían estar aprendidas implícitamente por el modelo o manejarse de otra manera (por ejemplo, ponderando la salida del modelo). La regla para "Consulta especializada" basada en características ambiguas también es una consideración de seguridad y robustez.

2.3. Parametrización de RandomForest Classifier

Los parámetros de entrada y salida para cada método en la clase OcularClassifier, son los siguientes:

`__init__(self, model_path=None)`

- **Entrada:**
 - **Self:** Referencia a la instancia del objeto.
 - **Model_path (opcional):** Ruta a un modelo de clasificación entrenado.
- **Salida:** Ninguna (es el constructor de la clase).
- **Uso:** Inicializa una nueva instancia de la clase OcularClassifier. Opcionalmente, puede recibir una ruta para cargar un modelo pre-entrenado (aunque en la implementación actual, esta funcionalidad está marcada como un marcador de posición).



Inteligencia Artificial

miopIA Visión

```

class OcularClassifier:
    def __init__(self, model_path=None):
        """
        Inicializa el clasificador.
        """
        self.classifier = RandomForestClassifier(random_state=42)
        if model_path:
            # En una aplicación real, cargarías tu modelo de clasificación entrenado aquí.
            # Para la demostración, entrenaremos uno simple más adelante.
            pass

```

_extract_features_from_image(self, image_path)

- **Entrada:**
 - **Self:** Referencia a la instancia del objeto.
 - **Image_path:** Una cadena de texto que representa la ruta al archivo de imagen del ojo.
- **Salida:**
 - Una lista de valores numéricos que representan las características extraídas de la imagen, en el siguiente orden: [Alineación Ocular (0-4), Enrojecimiento Conjuntiva (0-4), Claridad Córnea (0-4), Claridad Pupila/Cristalino (0-4), Tamaño/Simetría Pupila (0/1), Secreciones (0-4), Apariencia Párpados (0-3)].
 - **None** si no se puede leer la imagen.
- **Uso:** Este es un método interno (_ al inicio) que procesa una imagen dada su ruta, extrae características visuales relevantes y las devuelve como una lista numérica.



Inteligencia Artificial

miopIA Visión

```

def _extract_features_from_image(self, image_path):
    """
    Args:
        image_path (str): Ruta a la imagen del ojo.

    Returns:
        list: Una lista de valores numéricos que representan las características extraídas.
              [Alineación Ocular (0-4), Enrojecimiento Conjuntiva (0-4),
               Claridad Córnea (0-4), Claridad Pupila/Cristalino (0-4),
               Tamaño/Simetría Pupila (0/1), Secreciones (0-4),
               Apariencia Párpados (0-3)]
        Devuelve None si no se puede procesar la imagen.
    """
    img = cv2.imread(image_path)
    if img is None:
        print(f"Error: No se pudo leer la imagen en {image_path}")
        return None

```

train_classifier(self, image_folder, labels_dict)

- **Entrada:**
 - **Self:** Referencia a la instancia del objeto.
 - **Image_folder:** Una cadena de texto que representa la ruta a la carpeta que contiene las imágenes de entrenamiento.
 - **Labels_dict:** Un diccionario donde las claves son los nombres de archivo de las imágenes y los valores son las etiquetas numéricas correspondientes (0 a 5).
- **Salida:** Ninguna (el método entrena el modelo interno de la clase).
- **Uso:** Carga las imágenes de la carpeta especificada, extrae características de cada una usando `_extract_features_from_image`, asocia las características con sus etiquetas correspondientes (proporcionadas en `labels_dict`) y entrena el clasificador (`RandomForestClassifier`) con estos datos.



Inteligencia Artificial

miopIA Visión

```

def train_classifier(self, image_folder, labels_dict):
    """
    Extrae características de imágenes en una carpeta y entrena el modelo de clasificación.
    Args:
        image_folder (str): Ruta a la carpeta que contiene las imágenes de entrenamiento.
        labels_dict (dict): Diccionario mapeando nombres de archivo a etiquetas (0-5).
    """
    X_train = []
    y_train = []
    print(f"\nCargando imágenes de {image_folder} para entrenamiento...")
    for filename in os.listdir(image_folder):
        if filename.endswith(('.jpg', '.png', '.jpeg')): # Filtrar por extensiones de imagen
            image_path = os.path.join(image_folder, filename)
            features = self._extract_features_from_image(image_path)
            if features is not None and filename in labels_dict:
                X_train.append(features)
                y_train.append(labels_dict[filename])
            elif filename not in labels_dict:
                print(f"Advertencia: No se encontró etiqueta para {filename}. Se omitirá.")
  
```



`predict_visual_problem(self, image_path)`

- **Entrada:**
 - **Self:** Referencia a la instancia del objeto.
 - **Image_path:** Una cadena de texto que representa la ruta a la imagen de entrada que se desea clasificar.
- **Salida:**
 - Una cadena de texto que indica el problema visual predicho ("Visión Normal", "Estrabismo", "Conjuntivitis", "Cataratas", "Ojo Seco", "Consulta especializada").
 - Una cadena de texto indicando un error si la extracción de características falla.
- **Uso:** Extrae características de la imagen de entrada usando `_extract_features_from_image`, utiliza el clasificador entrenado para predecir la etiqueta numérica, y mapea la etiqueta numérica a una cadena de texto descriptiva del problema visual. También incluye reglas adicionales basadas en las características para refinar la predicción o sugerir una consulta especializada.

```

def predict_visual_problem(self, image_path):
    """
    Extrae características de una imagen y predice el problema visual.
    Args:
        image_path (str): Ruta a la imagen de entrada.

    Returns:
        str: Problema visual predicho o sugerencia de consulta especializada.
    """
    features = self._extract_features_from_image(image_path)
    if features is None:
        return "Error en la extracción de características de la imagen."

    # Convertir las características a un array numpy para la predicción
    features_array = np.array(features).reshape(1, -1)

    # Predecir usando el clasificador entrenado
    prediction_index = self.classifier.predict(features_array)[0]
    # Mapear el índice de vuelta a la etiqueta de cadena
    # Esto asume que tus etiquetas de entrenamiento corresponden a estos índices
    # 0: Visión Normal, 1: Estrabismo, 2: Conjuntivitis, 3: Cataratas, 4: Ojo Seco
    possible_problems = {
        0: "Visión Normal",
        1: "Estrabismo",
        2: "Conjuntivitis",
        3: "Cataratas",
        4: "Ojo Seco",
        5: "Consulta especializada" # Mapeo para el caso de "Consulta especializada"
    }
    predicted_problem = possible_problems.get(prediction_index, "Consulta especializada")
    
```



suggest_specialized_consultation(self, features)

- **Entrada:**
 - **Self:** Referencia a la instancia del objeto.
 - **Features:** Una lista de valores numéricos que representan las características extraídas de una imagen.
- **Salida:**
 - Un valor booleano (True o False). True si las características sugieren la necesidad de una consulta especializada, False en caso contrario.
- **Uso:** Este es un método auxiliar basado en reglas simples que evalúa las características extraídas y determina si la combinación de características justifica sugerir una consulta con un especialista, incluso si el clasificador predijo una categoría específica.



Inteligencia Artificial

miopIA Visión

```

def suggest_specialized_consultation(self, features):
    """
    Una función basada en reglas para sugerir consulta especializada
    si las características no se alinean claramente con condiciones conocidas o son ambiguas.
    """

    if any(f > 1 for f in features) and sum(features) < 5: # Algunos problemas, pero no graves o específicos
        return True
    return False

# --- Ejemplo de Uso ---
if __name__ == "__main__":
    # 1. Instanciar el clasificador
    ocular_classifier = OcularClassifier()

    # 2. Preparar DATOS DE ENTRENAMIENTO
    # Debes tener una carpeta con imágenes de entrenamiento y un diccionario con sus etiquetas.
    image_folder = '/content/Entrenamiento'
    entrenamiento_path = '/content/Entrenamiento'
    all_entries = os.listdir(entrenamiento_path)
    files_in_entrenamiento = [entry for entry in all_entries if os.path.isfile(os.path.join(entrenamiento_path, entry))]

    labels_dict = {}

    for file_name in files_in_entrenamiento:
        if file_name.startswith('normal'):
            labels_dict[file_name] = 0
        elif file_name.startswith('estrabismo'):
            labels_dict[file_name] = 1
        elif file_name.startswith('conjuntivitis'):
            labels_dict[file_name] = 2
        elif file_name.startswith('cataratas'):
            labels_dict[file_name] = 3
        elif file_name.startswith('ojito_seco'):
            labels_dict[file_name] = 4
  
```



3. EVALUACIÓN E IMPLEMENTACIÓN

3.1. Evaluación

La validez de un modelo predictivo, especialmente en el ámbito de la salud, es fundamental. Para nuestro proyecto de detección de condiciones visuales (visión normal, estrabismo, cataratas, conjuntivitis, ojos secos o consulta especializada), el método **Random Forest** no solo es una elección justificada, sino que su aplicación se valida por su capacidad inherente para abordar las particularidades de nuestros datos y la complejidad del problema.

La solidez de Random Forest en este contexto se fundamenta en varios pilares clave, directamente relacionados con nuestras **siete variables** (Alineación Ocular, Enrojecimiento de la Conjuntiva, Claridad/Opacidad de la Córnea, Claridad/Opacidad de la Pupila y el Cristalino, Tamaño y Simetría de la Pupila, Presencia de Secreciones o Descargas y Apariencia de los Párpados) y las **condiciones visuales a predecir**:

1. Robustez ante la Heterogeneidad de los Datos Visuales

Las variables que hemos definido, aunque estandarizadas, representan una **diversidad de información visual**. Algunas son medidas de alineación, otras de coloración, transparencia o presencia de secreciones. Random Forest sobresale en el manejo de esta heterogeneidad. A diferencia de modelos que exigen que los datos cumplan con ciertas distribuciones o linealidades, los árboles de decisión (base de Random Forest) pueden procesar eficazmente datos categóricos y ordinales sin una preprocessamiento complejo, lo cual es ideal para nuestras escalas de 0 a 3 o 0 a 4. Esta flexibilidad asegura que la riqueza de la información extraída de las 1722 imágenes se aproveche al máximo.



2. Detección de Patrones Intrincados para Diagnósticos Diferenciales

Las condiciones visuales a menudo comparten síntomas o presentan matices sutiles. Por ejemplo, tanto la conjuntivitis como los ojos secos pueden causar enrojecimiento, pero difieren en el tipo y la cantidad de secreciones o la apariencia de los párpados. Random Forest, al construir múltiples árboles que exploran diferentes subconjuntos de datos y características, tiene una capacidad excepcional para **descubrir patrones intrincados y relaciones no lineales** entre las variables. Esta habilidad es crucial para realizar diagnósticos diferenciales precisos entre condiciones que pueden parecer similares a primera vista, mejorando la validez de las predicciones del modelo al identificar las combinaciones específicas de síntomas que definen cada afección.

3. Fiabilidad ante la Variabilidad de las Imágenes Clínicas

Aunque hemos estandarizado el proceso de preparación de imágenes, siempre existirá una variabilidad inherente en las fotografías clínicas (iluminación, ángulos, expresiones faciales sutiles, etc.). Los errores menores en la cuantificación de las variables pueden considerarse "ruido" en los datos. La arquitectura de Random Forest, que agrega las predicciones de numerosos árboles entrenados en subconjuntos aleatorios de datos, lo hace **altamente resistente al ruido y a los valores atípicos**. Esta robustez confiere una mayor fiabilidad a nuestras predicciones, ya que el modelo es menos propenso a ser engañado por anomalías o inconsistencias menores en el procesamiento de las 1722 imágenes.

4. Capacidad de Generalización y Mitigación del Sobreajuste

Un modelo válido debe ser capaz de **generalizar bien** a nuevas imágenes, es decir, predecir correctamente las condiciones en pacientes no vistos durante el entrenamiento. El riesgo de sobreajuste (cuando un modelo memoriza los datos



de entrenamiento en lugar de aprender patrones generales) es una preocupación constante. Random Forest aborda esto de dos maneras fundamentales:

- * **Bagging:** Cada árbol se entrena con una muestra aleatoria (con reemplazo) del conjunto de datos.
- * **Selección aleatoria de características:** En cada división de un nodo, solo se considera un subconjunto aleatorio de las variables. Estas técnicas garantizan que los árboles sean diversos y que sus errores individuales se cancelen mutuamente al promediar sus predicciones, lo que resulta en un modelo de conjunto con una **baja varianza y una excelente capacidad de generalización**. Esto es vital para asegurar que las predicciones del proyecto sean válidas y aplicables en un entorno real.

5. Fundamentación en la Importancia de las Características

La capacidad de Random Forest para calcular la **importancia de cada característica** proporciona una validación intrínseca de su funcionamiento. Al identificar qué variables (por ejemplo, la opacidad del cristalino para cataratas o el enrojecimiento de la conjuntiva para conjuntivitis) son las más influyentes en las predicciones, podemos confirmar que el modelo está prestando atención a los factores clínicamente relevantes. Esta interpretabilidad no solo valida el modelo en sí, sino que también refuerza la confianza en sus decisiones, ya que se alinea con el conocimiento médico experto.



Inteligencia Artificial

miopiaVisión



[↑ Cambiar imagen](#) [Analizar imagen](#)

⚠ Conjuntivitis
Confianza: 94%

Inflamación de la conjuntiva con enrojecimiento y posible secreción

Características detectadas:

- Enrojecimiento conjuntival
- Posible secreción
- Signos inflamatorios

Recomendaciones:
Consultar médico para tratamiento apropiado. evitar tocarse los ojos



[↑ Cambiar imagen](#) [Analizar imagen](#)

👁 Estrabismo
Confianza: 85%

Desalineación de los ejes visuales, uno o ambos ojos no miran en la misma dirección

Características detectadas:

- Desalineación detectada
- Asimetría en la posición ocular
- Requiere medición del ángulo

Recomendaciones:
Consultar con oftalmólogo para evaluación y posible tratamiento correctivo



Inteligencia Artificial

miopia Visión



Cambiar imagen
Analizar imagen

Cataratas
Confianza: 96%

Opacidad en el cristalino que puede afectar la visión

Características detectadas:

- Opacidad en cristalino
- Reflejo pupilar alterado
- Posible pérdida de transparencia

Recomendaciones:

Evaluación oftalmológica para determinar grado y necesidad de cirugía

Próximos pasos sugeridos:

- Guardar esta imagen y resultado para mostrar al especialista
- Programar cita con oftalmólogo para confirmación
- Monitorear cualquier cambio en los síntomas
- Seguir las recomendaciones de cuidado ocular



Cambiar imagen
Analizar imagen

Ojos Secos
Confianza: 94%

Insuficiente producción de lágrimas o mala calidad del film lagrimal

Características detectadas:

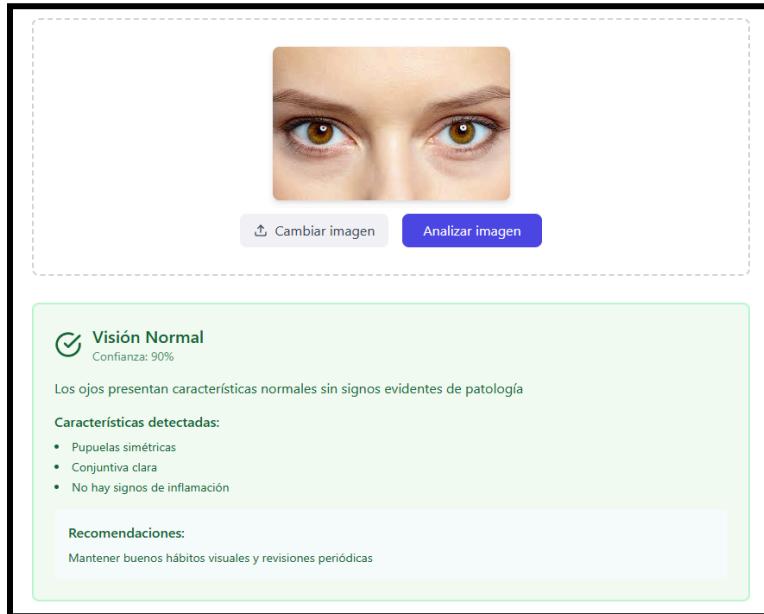
- Superficie ocular irregular
- Posible irritación
- Film lagrimal comprometido

Recomendaciones:

Usar lágrimas artificiales, evitar ambientes secos, consultar especialista



miopiaVisión



3.2. Implementación

El método “predict_visual_problem” toma la ruta de una imagen de ojo para predecir un problema visual. Primero, intenta extraer características numéricas de la imagen. Si falla, devuelve un error. Si tiene éxito, prepara estas características y las pasa a un clasificador “RandomForestClassifier” (que debe estar previamente entrenado) para obtener una predicción numérica.

Sin embargo, la predicción del modelo no es el resultado final directo. El código tiene reglas heurísticas fijas: si ciertas características superan umbrales específicos, el método anula la predicción del modelo y devuelve un problema predefinido (como "Conjuntivitis" si el enrojecimiento es alto). Si estas reglas no se activan, el método mapea la predicción numérica del modelo a un texto (como "Visión Normal"). Adicionalmente, una regla final basada en un método auxiliar puede sugerir "Consulta especializada" si las características son ambiguas o si el modelo predijo específicamente esa categoría.



Sólo si ninguna regla heurística ni la sugerencia de consulta especializada se aplican, se devuelve el resultado del mapeo de la predicción del modelo.

Para que funcione, el clasificador debe estar entrenado previamente, la ruta de la imagen debe ser válida y legible, y las técnicas de extracción de características y las reglas heurísticas implementadas deben ser adecuadas para las imágenes que se analizan.

3.3. Plataforma y Herramientas

Google Colab (Colaboratory) es un entorno de notebook Jupyter gratuito que se ejecuta completamente en la nube de Google. Permite escribir y ejecutar código Python (y otros lenguajes) a través del navegador. Proporciona acceso a hardware de cómputo gratuito (incluyendo GPUs y TPUs, aunque no se usan explícitamente aquí) y facilita el compartir documentos. El código se ejecuta en máquinas virtuales alojadas por Google.

Esta cuenta con grandes ventajas, ya que no requiere configuración local, permite la ejecución de celdas de código de forma interactiva, integra el acceso a Google Drive y otros servicios de Google, e incluye muchas bibliotecas científicas y de aprendizaje automático preinstaladas.

El sistema Operativo del Entorno de Ejecución es Linux ya que las máquinas virtuales proporcionadas por Google Colab ejecutan un sistema operativo basado en Linux. Esto es relevante porque las rutas de archivo (/content/Entrenamiento, /content/Prediccion) siguen la convención de directorios de Linux.

Para el código se utilizó un lenguaje llamado Python 3.x. Este es un lenguaje de programación de propósito general, muy popular en ciencia de datos y aprendizaje automático debido a su sintaxis clara y la gran cantidad de bibliotecas disponibles. Gracias a esto se pudieron implementar las siguientes bibliotecas:



cv2 (OpenCV): Es una biblioteca de visión por computadora de código abierto. Se utiliza para leer imágenes (cv2.imread), realizar conversiones de espacio de color (cv2.cvtColor), aplicar filtros (cv2.filter2D), detectar bordes (cv2.Canny) y detectar círculos (cv2.HoughCircles). Es fundamental para las operaciones de pre-procesamiento y extracción de características de las imágenes de ojos.

Numpy: Fundamental para la computación numérica en Python. Se utiliza en trabajos con arrays y matrices (por ejemplo, para manipular datos de imagen, calcular proporciones, varianzas, etc.), que son esenciales para el procesamiento de imágenes y la preparación de datos para el modelo de aprendizaje automático. Se usa para crear arrays (np.array), manipularlos (reshape), y realizar cálculos sobre ellos (np.sum, np.mean, np.var, np.around).

Os: Módulo estándar de Python que proporciona una forma de interactuar con el sistema operativo. En este código, se utiliza principalmente para listar archivos en directorios (os.listdir) y construir rutas de archivo de manera segura (os.path.join). Es necesario para leer todas las imágenes de las carpetas de entrenamiento y predicción.

Sklearn.ensemble.RandomForestClassifier: Parte de la biblioteca scikit-learn, una de las más populares para aprendizaje automático en Python. RandomForestClassifier es un algoritmo de clasificación basado en conjuntos (ensemble) que construye múltiples árboles de decisión y combina sus predicciones para obtener un resultado más robusto. Se utiliza como el modelo de aprendizaje automático principal para clasificar las características extraídas de las imágenes.

Los archivos de Datos Utilizados son los siguientes:

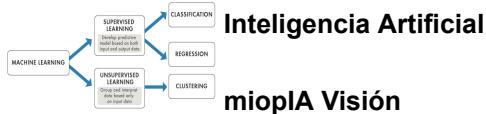
Imágenes de Entrenamiento: Archivos de imagen (con extensiones .jpg, .png, .jpeg) ubicados en la carpeta especificada por la variable image_folder, que se



establece como /content/Entrenamiento. Estas imágenes se usan junto con sus etiquetas para entrenar el modelo.

Diccionario de Etiquetas (labels_dict): Un diccionario creado en el código que mapea los nombres de archivo de las imágenes de entrenamiento a etiquetas numéricas (0 a 5). Es esencial para el proceso de entrenamiento supervisado.

Imágenes de Predicción: Archivos de imagen (con las mismas extensiones) ubicados en la carpeta especificada por la variable prediction_folder, que se establece como /content/Prediccion. Estas imágenes son las que el clasificador intenta analizar para predecir un problema visual después de haber sido entrenado.



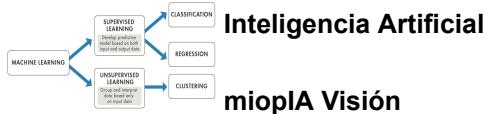
3. CONCLUSIONES

Conclusiones del Caso de Aplicación Seleccionado

- **Impacto Social Significativo:** El proyecto busca revolucionar la identificación y gestión de condiciones visuales comunes, como visión normal, estrabismo, cataratas, conjuntivitis y ojos secos, con el fin de optimizar los tiempos de diagnóstico y mejorar los pronósticos y la calidad de vida de los pacientes.
- **Democratización de la Salud Visual:** A través de la aplicación de la inteligencia artificial, se pretende democratizar el acceso a soluciones de salud visual, contribuyendo a comunidades más saludables y productivas.
- **Enfoque en la Prevención y Detección Temprana:** El sistema se centra en la predicción temprana y eficaz de diversas condiciones visuales, lo que permite intervenciones oportunas.

Conclusiones de la Técnica Seleccionada (Random Forest)

- **Robustez y Versatilidad:** El algoritmo Random Forest se justifica por su robustez, especialmente al manejar variables ordinales (como las siete variables clave extraídas de las imágenes oculares), lo que simplifica el preprocesamiento de datos.
- **Manejo de Relaciones Complejas:** Es capaz de capturar interacciones complejas y relaciones no lineales entre las variables, lo que resulta en una mayor precisión predictiva para las condiciones visuales.
- **Fiabilidad y Estabilidad del Modelo:** Demuestra tolerancia a datos ruidosos y valores atípicos, comunes en el procesamiento de imágenes médicas, lo que asegura un modelo más estable y confiable.



- **Mitigación del Sobreajuste:** Reduce eficazmente el riesgo de sobreajuste (overfitting) mediante la construcción de múltiples árboles de decisión, lo que garantiza la diversidad y mejora la generalización del modelo.
- **Capacidad de Interpretación:** Permite identificar la importancia de las características, es decir, cuáles de las siete variables son más influyentes en la predicción de cada condición visual, ofreciendo una valiosa interpretabilidad.

Conclusiones del Método Seleccionado (Sistema de Predicción Basado en Características Visuales)

- **Eficacia en la Extracción de Características:** El método se basa en la extracción y análisis de siete variables clave de imágenes oculares (alineación, enrojecimiento, opacidad de córnea/pupila/cristalino, tamaño/simetría de pupila, secreciones y apariencia de párpados), transformando la información visual en datos estructurados.
- **Automatización del Proceso:** El preprocesamiento de imágenes y la extracción de características son automatizados, lo que optimiza el flujo de trabajo y la preparación de los datos para el modelo de IA.
- **Potencial de Predicción:** El sistema, entrenado con un conjunto de 1722 imágenes de Kaggle, demuestra la capacidad de predecir eficazmente diferentes condiciones visuales, validando el enfoque metodológico.

Consideraciones Personales (Implícitas en el Proyecto)

- **Compromiso con la Innovación:** El proyecto refleja un fuerte compromiso con la innovación en el campo de la salud, utilizando tecnologías de vanguardia para abordar problemas médicos.



- **Interdisciplinariedad:** La complejidad del proyecto sugiere una colaboración interdisciplinaria entre expertos en inteligencia artificial, oftalmología y ciencia de datos.
- **Potencial de Escalabilidad y Mejora Continua:** Aunque el proyecto presenta una base sólida, se anticipa la posibilidad de futuras mejoras y expansiones, como el aumento del conjunto de datos o la incorporación de nuevas características para perfeccionar el rendimiento del modelo.